朴素贝叶斯模型

1 背景

在第一章，我们学习了朴素贝叶斯模型的特殊情况，即特征和类别都是二值的情况。本项目计划先将模型推广到有限多值特征和多类别的情况，然后再把该模型应用到公开数据集 UCI Dry Bean 的干豆分类问题，测试模型的分类效果。公开数据集 UCI Dry Bean 包含了 13611 颗干豆的 16 个形状测量值，包括面积、周长、主轴长度等；干豆类别包含了 7 个品种：

- Seker;
- Barbunya;
- Bombay;
- Cali;
- Dermason;
- Horoz;
- Sira.

请你通过阅读第二节的介绍熟悉数据文件的组成和格式，再完成探究问题，并撰写探究报告。

2 数据文件描述

2.1 原始数据集：`bean_raw.csv`

该文件包含了原始数据集中的 13611 条数据。数据总共有 20 列。其中第 1 列为数据 ID，第 20 列 `Class` 是干豆品种标签，第 2 列和第 3 列为数据集分割信息，第 4 列到第 19 列为 16 个干豆形状特征，具体字段说明如下：

字段	含义
id	数据 ID
partition	属于训练数据集还是测试数据集（见后文描述）
in_train_1000	数据是否属于训练数据集 2（见后文描述）
Area	面积
Perimeter	周长
MajorAxisLength	长轴长度
MinorAxisLength	短轴长度
AspectRation	宽高比
Eccentricity	偏心率
ConvexArea	凸包面积
EquivDiameter	等效直径
Extent	边界框内像素数与豆状区域像素数的比值
Solidity	硬度
roundness	圆度
Compactness	紧实度
ShapeFactor1	形状因子 1
ShapeFactor2	形状因子 2
ShapeFactor3	形状因子 3
ShapeFactor4	形状因子 4
Class	数据类别

需要注意：数据特征为连续数值。为了能够应用有限类别的朴素贝叶斯模型，我们对数据进行了预处理，将连续数值离散化成有限个取值范围，参考以下预处理后的数据文件。

2.2 预处理后的训练数据集 1：bean_train.csv

该文件包含了预处理后的 9526 条训练数据，用于训练朴素贝叶斯模型。数据集包含 18 列，其中第 1 列为数据 ID，第 2 列到第 17 列对应于原始数据集的数据特征，并根据数据数值大小离散化为 0,1,2 三种数值。第 18 列为干豆类别。

2.3 预处理后的训练数据集 2：bean_train_1000.csv

该文件包含了预处理后的训练数据中的 1000 条，用于测试较少数据训练的模型的分类准确率。

2.4 预处理后的测试数据集：bean_test.csv

该文件包含了预处理后的 4085 条测试数据。数据集包含 18 列，其中第 1 列为数据 ID，第 2 列到第 17 列对应于原始数据集的数据特征，并根据数据数值大小离散化为 0,1,2 三种数值。第 18 列为干豆类别。数据预处理方式和训练数据保持一致。

3 探究问题

第 1 步：推广朴素贝叶斯模型

首先请你将课堂上介绍的二值情况的朴素贝叶斯模型推广到一般情况。我们假设

> 数据集包含 m 个特征，理解为随机变量，分别记作 $X_1, X_2, \ldots, X_m$，其中特征 X_i 的所有取值的数量为 k_i，分别记作 $x_{i,1}, x_{i,2}, \ldots, x_{i,k_i}$；类别标签也理解为随机变量，记作 Y，所有取值的数量为 k，分别记作 $y_1, \ldots, y_k$。

在当前设定下，陈述并推导朴素贝叶斯模型，必须包含但不限于如下要点：

(1) 直接使用贝叶斯公式，为什么会有维数灾难？

(2) 在当前设定下，独立性假设是什么？

(3) 加入了独立性假设后，朴素贝叶斯模型如何利用贝叶斯公式计算条件概率，进而分类数据。

(4) 对应的拉普拉斯平滑的修正值应该如何取值？解释理由。

第 2 步：干豆数据集分类

请你将推广后的朴素贝叶斯模型应用到 UCI Dry Bean 数据集。

(1) 自学机器学习的知识，陈述什么是分类问题，并且解释训练集和测试集的作用。

(2) 利用预处理后的训练数据集 2 训练朴素贝叶斯模型，并在预处理后的测试数据集上测试分类准确率。

(3) 利用预处理后的训练数据集 1 训练朴素贝叶斯模型，并在预处理后的测试数据集上测试分类准确率。

(4) 对比不同训练集得到的分类准确率，是否有明显差异？分析并解释有明显差异或没有明显差异的原因。

第 3 步：思考问题

(1) 我们对于数据进行了离散化处理，如果直接使用连续数值，是否可以修改朴素贝叶斯模型允许连续数值特征？

(2) 独立性假设是否合理？例如面积和等效直径两项数据完全相关，重复使用相关特征是否影响分类结果？

第 4 步：改进分类结果

从这一步开始，你可以使用原始数据集进行数据分类，你可以尝试任何你觉得可行的分类模型，可以尝试以任意方式对数据进行预处理。请你选择一个分类模型和一个预处理方式，尽可能地取得更高的分类准确率。注意：分类准确率仍然是在原始数据集中 partition 字段取值为 TEST 的数据构成的测试数据集中计算。

(1) 请你详细地描述你采用的数据预处理方法，你采用的模型或算法，以及使用的模型参数等，确保助教可以复现你的结果。报告你的分类准确率。

(2) 比较你的分类准确率与第二步中的朴素贝叶斯模型的分类准确率，分析分类准确率提高、接近或降低的可能原因。

注：这一步得分不完全取决于分类准确率的提升幅度，不需要无上限投入时间刷分类准确率，并且请尽力避免过拟合测试集。